

Proyecto - Monografía

Domínguez Aspilcueta, Pedro Francisco - 201910375

Ríos Vásquez, Paul Jeremy - 201910038

Lama Carrasco, Miguel Angel - 201910199



Universidad de Ingeniería y Tecnología

Ciencia de la computación

Análisis y Diseño de Algoritmos 1.00

Docente: Gutierrez Alva, Juan Gabriel

TA: Lopez Condori, Rodrigo

1. Problema de codificación de texto

Problema MIN-COD Dada una cadena s sobre el conjunto C , encontrar una codificación de C óptima.

- Sea s una cadena no vacía tal que $s = \{a_1 a_2 \cdots a_n\}$.
- $\{C_0, C_1, C_2, C_3\}$ los modos de codificar a .
- B una cadena de dos bits $\{00, 01, 10, 11\}$ que indica cual C comienza una codificación de s .
- $\{T_0, T_1, T_2, T_3\}$ las cadenas de transición a otro C . Tomando en cuenta que T puede ser vacío si no se requiere ninguna transición.

Podemos suponer que una cadena s siempre puede ser codificada por al menos un modo de codificación C . Y decimos que r es una solución óptima tal que r empieza con una cadena B de dos bits seguido de un número de codificaciones y transiciones mínimos. $r = \{B \cdot C(a_1) \cdot T \cdot C(a_2) \cdot T \cdot C(a_3) T \cdots T \cdot C(a_n)\}$

1.1. Pregunta 1

Heurística Voraz: Utilizar el modo de codificación que permita una codificación mínima para los caracteres a_i y a_{i+1} .

RECIBE: un cadena s con un número de caracteres par no vacía.

DEVUELVE: Una cadena r de bits que codifica a s y su tamaño.

VORAZ(s)

- 1: $C_j = C_0$
- 2: **for** $i = 0$ to $n - 1$, step = 2 **do**
- 3: C_k es el modo mínimo de codificación válido para a_i, a_{i+1} .
- 4: **if** $C_j \neq C_k$ **then**
- 5: $r += T_k$
- 6: $r += C_k(a_i)$
- 7: $r += C_k(a_{i+1})$
- 8: $j = k$
- 9: **return** r

1.2. Pregunta 2

Sea X una solución óptima para el problema. Existen tres casos dependiendo de la codificación del último carácter a_n de s .

- **Caso 1:** $C_j(a_n) \notin X$. En ese caso, a_n no puede ser codificado por el modo C_j . Por lo que no existe una codificación óptima que incluya a $C_j(a_n)$.
- **Caso 2:** $C_j(a_n) \in X$. En ese caso, a_n puede ser codificado por el modo C_j . Considere que $X' = X/\{a_n\}$. Note que X' es una solución óptima para el subproblema $s = a_1a_2 \cdots a_{n-1}$.
¿Porqué? Considere por contradicción que X' no es una solución óptima, entonces existe una solución Y' para este subproblema que codifica con menor tamaño que X' . Luego $Y = Y' \cup \{n\}$ sería una solución mejor que X para el problema original, siendo esto una contradicción. Tomando en cuenta que debe haber una transición si a_{n-1} no puede ser codificado por el modo C_j .

Lemma 2.1: Sea $OPT(i, j)$ el tamaño de la codificación mínima óptima para el subproblema que considera a la subcadena $s' = \{a_1a_2 \cdots a_i\}$.

$$OPT(i, j) \begin{cases} B_j + C_j(a_i) & i = 1; a_i \text{ se puede codificar con } C_j \\ \infty & a_i \text{ no se puede codificar con } C_j \\ \min\{OPT(i-1, j) + C_j(a_i), & i > 1 \\ OPT(i-1, (j+1) \bmod 4) + T_{(j+1) \bmod 4} + C_j(a_i), \\ OPT(i-1, (j+2) \bmod 4) + T_{(j+2) \bmod 4} + C_j(a_i), \\ OPT(i-1, (j+3) \bmod 4) + T_{(j+3) \bmod 4} + C_j(a_i)\} \end{cases}$$

Prueba: Sea X una solución óptima para el subproblema que considera a la subcadena $\{a_1a_2 \cdots a_i\}$. Suponga que a_i puede ser codificado por C_j . Sea $X' = X/\{a_i\}$. Note que X' es una solución óptima para el subproblema. (Vea análisis anterior). Por lo tanto:

- Cuando a_{i-1} puede ser codificado por el modo C_j . Entonces:

$$OPT(i, j) = OPT(i-1, j) + C_j(a_i)$$

- Cuando a_{i-1} no puede ser codificado por el modo C_j . Se debe añadir una transición T_k del modo C_k donde $1 \leq k \leq 4$ que sí codifica a_{i-1}

$$OPT(i, j) = \min\{OPT(i-1, (j+1) \bmod 4) + T_{(j+1) \bmod 4} + C_j(a_i), \\ OPT(i-1, (j+2) \bmod 4) + T_{(j+2) \bmod 4} + C_j(a_i), \\ OPT(i-1, (j+3) \bmod 4) + T_{(j+3) \bmod 4} + C_j(a_i)\}$$

Ahora suponga que a_i no puede ser codificado por C_j . Entonces:

$$OPT(i, j) = \infty$$

El análisis anterior nos permite diseñar un algoritmo recursivo para el problema.

1.3. Pregunta 3

RECIBE: un índice final i de una cadena s y un índice j de C .

DEVUELVE: Una cadena r que codifica a s de manera mínima óptima con $C_j(a_i)$.

OPT(i, j)

- 1: **if** (a_i puede ser codificado por C_j) y $i = 1$ **then**
- 2: **return** $B_j + C_j(a_i)$
- 3: **if** (a_i no puede ser codificado por C_j) **then**
- 4: **return** ∞
- 5: $A_0 = C_j(a_i)$
- 6: $A_1 = T_{(j+1) \bmod 4} + C_j(a_i)$
- 7: $A_2 = T_{(j+2) \bmod 4} + C_j(a_i)$
- 8: $A_3 = T_{(j+3) \bmod 4} + C_j(a_i)$
- 9: $r = \min(OPT(i-1, j) + A_0, OPT(i-1, (j+1) \bmod 4) + A_1, OPT(i-1, (j+2) \bmod 4) + A_2, OPT(i-1, (j+3) \bmod 4) + A_3)$
- 10: **return** r

RECIBE: un cadena s no vacía.

DEVUELVE: Una cadena que codifica a s de manera mínima óptima.

MIN-COD(s)

- 1: Sea a_n el caracter final de s .
- 2: **return** $\min(OPT(a_n, 0), OPT(a_n, 1), OPT(a_n, 2), OPT(a_n, 3))$

1.3.1. Complejidad

En $OPT(i, j)$ se realizan cuatro llamadas recursivas para intentar codificar con los modos C_1, C_2, C_3, C_4 a cada caracter de la cadena s . Por lo tanto, $T(n) = \Omega(4^n)$.

En $MIN-COD(s)$ se envía a $OPT(i, j)$ los cuatros modos diferentes con los que se puede codificar el caracter a_n . Sin embargo, aún cuando se llama cuatro veces a OPT , la recursividad total sigue siendo $\Omega(4^n)$.

1.4. Pregunta 4

RECIBE: un índice final i de una cadena s y un índice j de C .

DEVUELVE: Una cadena r que codifica a s de manera mínima óptima con $C_j(a_i)$.

OPT-MEMOIZADO(i, j)

- 1: **if** $i == 0$ OR $A[i][j] \neq \infty$ **then**
- 2: **return** $A[i][j]$
- 3: **if** a_i puede ser codificado por C_j **then**
- 4: $A_0 = \text{OPT-MEMOIZADO}(i - 1, j) + C_j(a_i)$
- 5: $A_1 = \text{OPT-MEMOIZADO}(i - 1, (j + 1) \bmod 4) + T_{(j+1) \bmod 4} + C_j(a_i)$
- 6: $A_2 = \text{OPT-MEMOIZADO}(i - 1, (j + 2) \bmod 4) + T_{(j+2) \bmod 4} + C_j(a_i)$
- 7: $A_3 = \text{OPT-MEMOIZADO}(i - 1, (j + 3) \bmod 4) + T_{(j+3) \bmod 4} + C_j(a_i)$
- 8: $A[i][j] = \min(A_0, A_1, A_2, A_3)$
- 9: **return** $A[i][j]$

RECIBE: un cadena s no vacía.

DEVUELVE: Una cadena que codifica a s de manera mínima óptima.

MIN-COD-MEM(s)

- 1: $A[0][0] = 00$
- 2: $A[0][1] = 01$
- 3: $A[0][2] = 10$
- 4: $A[0][3] = 11$
- 5: **for** $i = 1$ to n **do**
- 6: $A[i][0 \dots 3] = \infty$
- 7: Sea a_n el caracter final de s .
- 8: **return** $\min(\text{OPT}(a_n, 0), \text{OPT}(a_n, 1), \text{OPT}(a_n, 2), \text{OPT}(a_n, 3))$

1.4.1. Complejidad

En $\text{OPT}(i, j)$ se realizan cuatro llamadas recursivas para intentar codificar con los modos C_1, C_2, C_3, C_4 a cada caracter de la cadena s . Sin embargo, una vez que se haya calculado la solución $A[i][j]$ esta se guarda en una matriz A . Asumiendo que la concatenación de bits de las líneas 4-7 tiene costo $O(1)$ entonces la recurrencia memoizada es $O(n)$.

En $\text{MIN-COD}(s)$ se envía a $\text{OPT}(i, j)$ los cuatros modos diferentes con los que se puede codificar el caracter a_n . En la matriz A se asignan los valores previos iniciales B , así como valores ∞ para el resto de la matriz.

1.5. Pregunta 5

RECIBE: una cadena s .

DEVUELVE: Una cadena r que codifica a s de manera mínima óptima.

MIN-COD-DIN(s)

```
1: Sea  $A$  una matriz que guarda la solución.
2:  $A[0][0] = 00$ 
3:  $A[0][1] = 01$ 
4:  $A[0][2] = 10$ 
5:  $A[0][3] = 11$ 
6: for  $i = 1$  to  $n$  do
7:    $A[i][1] = \infty$ 
8:    $A[i][2] = \infty$ 
9:    $A[i][3] = \infty$ 
10:   $A[i][4] = \infty$ 
11:  for  $j = 0$  to  $3$  do
12:    if Si  $a_i$  puede ser codificado con  $C_j$  then
13:       $M_1 = A[i-1][j] + C_j(a_i)$ 
14:       $M_2 = A[i-1][(j+1) \bmod 4] + T_{(j+1) \bmod 4} + C_j(a_i)$ 
15:       $M_3 = A[i-1][(j+2) \bmod 4] + T_{(j+2) \bmod 4} + C_j(a_i)$ 
16:       $M_4 = A[i-1][(j+3) \bmod 4] + T_{(j+3) \bmod 4} + C_j(a_i)$ 
17:       $A[i][j] = \min(M_1, M_2, M_3, M_4)$ 
18:
19:  $r = \min(A[n][1], A[n][2], A[n][3], A[n][4])$ 
20: return  $r$ 
```

1.5.1. Complejidad

En $MIN-COD-DIN(s)$ asumiendo que la concantenación de cadenas de bits es $O(1)$ es claro que el algoritmo es $\Omega(n)$. Los cuatros modos diferentes de la recurrencia aumentan el costo lineal en cuatro. La respuesta óptima del algoritmo está en el valor mínimo de $A[n][1]$, $A[n][2]$, $A[n][3]$ y $A[n][4]$.

2. Software de codificación y decodificación

- 2.1. Pregunta 6 (Codificación heurística)
- 2.2. Pregunta 7 (Codificación óptima)
- 2.3. Pregunta 8 (Decodificación)
- 2.4. Pregunta 9 (Software de codificación y decodificación)
- 2.5. Pregunta 10 (Análisis experimental)